

Redes neuronales continuas en forma cerrada

Análisis matemático de las CfC del MIT/IST Austria — solución cerrada de las ecuaciones LTC y $O(k)$

Resumen

Solución cerrada de las ecuaciones LTC: $O(k)$ y hasta $10^5 \times$ más rápido que Neural ODEs.

Las CfC del MIT/IST Austria resuelven las limitaciones de velocidad de los Neural ODEs aproximando la solución de las ecuaciones LTC *en forma cerrada* —sin solucionadores numéricos. Logran complejidad $O(k)$ con mejoras de velocidad de hasta cinco órdenes de magnitud manteniendo o mejorando la precisión.

Ecuación fundamental de las CfC

$$x(t) \approx (x(0) - A) e^{-[w_\tau + f(I(t), \theta)]t} f(-I(t), \theta) + A.$$

1. Indicadores

COMPLEJIDAD

 $O(k)$

lineal en pasos

SPEED-UP

 $\leq 10^5$

vs. Neural ODE

MEMORIA

↓

durante entrenamiento

PRECISIÓN

↑

vs. baseline LTC

De redes discretas a continuas

Las Neural ODEs reformulan las redes como un sistema dinámico continuo.

2. Discretas

Las redes neuronales tradicionales operan en pasos discretos:

$$\mathbf{h}_{t+1} = f(\mathbf{h}_t, \mathbf{x}_t; \theta),$$

con $\mathbf{h}_t$ el estado oculto, $\mathbf{x}_t$ la entrada y θ los parámetros.

3. Continuas (Neural ODEs)

$$\frac{d\mathbf{x}(t)}{dt} = F(\mathbf{x}(t), I(t), \theta),$$

con $\mathbf{x}(t)$ el vector de estado, $I(t)$ la entrada y F continua y no lineal.

El problema de los solucionadores numéricos

La principal limitación de las Neural ODEs es la necesidad de *resolver numéricamente* estas ecuaciones (Euler, Runge-Kutta, ...):

- alto coste computacional: cada paso de entrenamiento resuelve una ODE,
- precisión vs. eficiencia: mayor precisión $\Rightarrow$ mayor coste,
- escalabilidad limitada para problemas grandes.

La complejidad temporal de estos solvers es $O(k \cdot p)$, donde p es el orden del método.

Redes LTC

Liquid Time-constant: la base sobre la que se construyen las CfC.

4. Formulación matemática

Dinámica de un nodo LTC

$$\frac{dx(t)}{dt} = -(w_\tau + f(I(t), \theta)) x(t) + A f(I(t), \theta),$$

con

- $x(t)$ — estado de la neurona postsináptica en t ,
- $w_\tau > 0$ — tiempo característico,
- $f(I(t), \theta)$ — no lineal, positiva, creciente y acotada,
- A — potencial de reversión sináptica (bias).

5. Solución exacta para entradas continuas

$$x(t) = (x(0) - A) e^{-w_\tau t} e^{-\int_0^t f(I(s)) ds} + A.$$

El cuello de botella

La integral $\int_0^t f(I(s)) ds$ no siempre tiene solución analítica sencilla, especialmente con $f(I(s))$ compleja o $I(s)$ que varía continuamente de manera arbitraria. De ahí la necesidad del solver numérico —y el coste asociado.

Solución en forma cerrada (CfC)

Aproximación de la integral problemática.

6. Derivación de la aproximación

Aproximación clave

$$e^{-\int_0^t f(I(s)) \, ds} \approx e^{-f(I(t))t} \cdot f(-I(t), \theta).$$

Sustituyendo en la solución exacta se obtiene la *forma cerrada*:

$$x(t) \approx (x(0) - A) e^{-[w_\tau + f(I(t), \theta)]t} f(-I(t), \theta) + A.$$

7. Validez matemática

Bajo qué condiciones la aproximación es buena

- Para entradas constantes por tramos, la aproximación es *exacta* en cada segmento.
 - Para variaciones suaves de $I(t)$, el error es $O(\Delta t^2)$.
 - La aproximación preserva las propiedades de estabilidad del sistema original.
- El error es despreciable para la mayoría de aplicaciones prácticas.

Complejidad y eficiencia

Las CfC alcanzan $O(k)$, equivalente a las RNN tradicionales.

Arquitectura	Complejidad temporal	Comentario
CfC	$O(k)$	lineal en pasos de tiempo
RNN tradicional	$O(k)$	lineal en pasos de tiempo
ODE-RNN	$O(k \cdot p)$	p orden del solver numérico
Transformer	$O(n \cdot k)$	n longitud de secuencia

Mejoras de rendimiento empíricas

- Entre 10 y 10^5 veces más rápidas que modelos basados en ODEs.
- Reducción significativa de memoria durante el entrenamiento.
- Gradientes más estables durante la retropropagación.

Tiempo explícito

El tiempo aparece directamente en la ecuación: ideal para muestreo irregular.

Formulación temporal explícita

$$x(t) = \sigma(-f(x, I; \theta_f) t) \odot g(x, I; \theta_g) + [1 - \sigma(-f(x, I; \theta_f) t)] \odot h(x, I; \theta_h),$$

con σ logística, $\odot$ producto de Hadamard y f, g, h no lineales entrenables.

Interpretación


Es una interpolación ponderada por tiempo entre dos estados:

- $g(x, I; \theta_g)$ — estado inicial / corto plazo,
- $h(x, I; \theta_h)$ — estado de equilibrio / largo plazo,
- $f(x, I; \theta_f)$ — controla la velocidad de transición.

Cuando $t \rightarrow 0$, $x(t) \approx g$. Cuando $t \rightarrow \infty$, $x(t) \approx h$.

Espacio de soluciones

Diagrama de Venn: las CfC ocupan un espacio único.



Las CfC combinan las ventajas de las Neural ODEs (operación en tiempo continuo) con la eficiencia computacional de las RNN tradicionales, ocupando un espacio único en el panorama de arquitecturas neuronales.

Limitaciones e implicaciones

Lo que las CfC no resuelven.

8. Gradientes desvanecientes

Decaimiento exponencial

El término exponencial $e^{-[w_\tau + f(I(t), \theta)] t}$ puede generar gradientes desvanecientes para secuencias largas:

$$\left\| \frac{\partial x(t)}{\partial \theta} \right\| \propto e^{-\alpha t},$$

con $\alpha > 0$ relacionada con w_τ y $f(I(t), \theta)$.

9. Invertibilidad no garantizada

A diferencia de las Neural ODEs puras, las CfC *no* garantizan la invertibilidad del sistema. Si $\Phi : x(t_1) \mapsto x(t_2)$ es el operador de evolución, no podemos garantizar que exista Φ^{-1} tal que $\Phi^{-1}(\Phi(x)) = x$ para todo x . Esta limitación restringe aplicaciones donde la reversibilidad temporal es crítica (ciertos modelos generativos, sistemas físicos conservativos).

Cuándo elegir CfC

Criterios matemáticos de selección.

Dominios óptimos

- series temporales médicas
- datos financieros irregulares
- sensores robóticos
- conducción autónoma
- análisis de sentimientos
- modelado físico
- sistemas de control
- análisis biomédico
- predicción climática
- procesamiento de señales

Criterios de selección

Las CfC son preferibles cuando:

- los datos presentan muestreo irregular ($t_{i+1} - t_i$ no constante);
- la eficiencia computacional es crítica ($\text{tiempo}_{\text{CfC}} \ll \text{tiempo}_{\text{ODE}}$);
- las dependencias temporales no son extremadamente largas ($\text{lag} < O(100)$);
- la interpretabilidad es importante.

Para modelado de lenguaje con dependencias muy largas, los *Transformers* siguen siendo más adecuados.

Conclusión

Las CfC representan un avance significativo: solución matemáticamente elegante para modelar procesos continuos eficientemente. Eliminan los solucionadores numéricos costosos, reducen la complejidad a $O(k)$, ofrecen mejoras de velocidad de hasta cinco órdenes de magnitud, mantienen o mejoran la precisión y modelan explícitamente el tiempo —ampliando el horizonte del aprendizaje profundo desde la medicina hasta la robótica.

Referencias

- [1] Hasani, R., Lechner, M., Amini, A., Rus, D., & Grosu, R. *Liquid Time-constant Networks*. AAAI, 2021.

- [2] Chen, T. Q., Rubanova, Y., Bettencourt, J., & Duvenaud, D. K. *Neural Ordinary Differential Equations*. NeurIPS, 2018.
- [3] Dupont, E., Doucet, A., & Teh, Y. W. *Augmented Neural ODEs*. NeurIPS, 2019.
- [4] Lechner, M., & Hasani, R. *Learning Long-Term Dependencies in Irregularly-Sampled Time Series*. NeurIPS, 2020.
- [5] Vaswani, A. et al. *Attention Is All You Need*. NeurIPS, 2017.

Patricio Hernández Ballester · @MevakeshEmetGPT

Ingeniero de prompts